

# Predicción del Costo Marginal de Generación (CMg) en un Sistema Energético Marginalista utilizando GCNs y Transformers: Un Enfoque Comparativo para Series Temporales

Gonzalo Iglesias, Nicolás Sotelo, Maximiliano Cruz

## 1. Introducción

La industria energética chilena enfrenta desafíos crecientes en la predicción del **Costo Marginal de Generación (CMg)**, un indicador fundamental en el mercado eléctrico marginalista. La alta penetración de energías renovables, particularmente en zonas de sobreoferta, ha aumentado la *volatilidad en los precios de la energía* y ha exacerbado problemas de congestión en la transmisión, resultando en pérdidas de eficiencia y eventos de *curtailment*. Para abordar este problema, el presente proyecto propone un modelo avanzado de Deep Learning que predice el CMg utilizando tres enfoques arquitectónicos: una combinación de **Red Neuronal Convolutiva de Grafos (GCN)** y **RNN/GRU/LSTM** para capturar tanto las interacciones espaciales en la red de transmisión como las variaciones temporales; un **Transformer** para series temporales; y un modelo híbrido **Transformer + CNN** para capturar patrones estacionales y relaciones de largo alcance.

Este proyecto busca evaluar el desempeño de estas arquitecturas en la predicción continua del CMg, abordando así el desafío de la variabilidad en los precios y contribuyendo al conocimiento científico mediante un análisis comparativo de modelos de deep learning aplicados a la industria energética.

## 2. Descripción del Problema

El sistema energético chileno opera bajo un *modelo marginalista*, en el cual el precio de la electricidad es determinado por el costo de la última unidad de energía necesaria para satisfacer la demanda. Este enfoque, junto con la creciente participación de energías renovables, ha llevado a fluctuaciones en el CMg, especialmente en momentos de sobreoferta y congestión de transmisión. Estas fluctuaciones dificultan la optimización de estrategias de arbitraje y almacenamiento, limitando las decisiones de los generadores sobre cuándo almacenar o verter energía en el mercado.

Este proyecto propone un modelo de deep learning para predecir el CMg y anticipar fluctuaciones de precio, proporcionando a los generadores una herramienta

para optimizar sus decisiones de arbitraje en un contexto de alta variabilidad. Además, el proyecto tiene como objetivo determinar qué arquitectura de modelo (GCN + RNN/GRU/LSTM, Transformer o Transformer + CNN) es la más efectiva para captar la naturaleza de los datos y proporcionar predicciones precisas en un sistema con dependencias espaciales y temporales complejas.

## 3. Datos

Los datos utilizados provendrán de fuentes abiertas del sector energético, incluyendo:

- **CMg Histórico:** Datos de precios de generación marginal, disponibles por zona y en intervalos de tiempo regulares.
- **Demanda y Oferta de Energía por Tipo y Región:** Datos de generación de energía renovable (solar, eólica) y térmica, segmentados geográficamente.
- **Restricciones de Transmisión y Congestión:** Datos que reflejan la capacidad y limitaciones de transmisión entre distintas zonas, proporcionando la estructura de aristas para el modelo de GCN.

Los datos incluirán tanto series temporales como relaciones espaciales entre las zonas de generación y consumo, permitiendo a cada modelo explotar distintos aspectos de la estructura y comportamiento del sistema energético.

## 4. Técnicas a Utilizar

Para abordar el problema, se compararán tres arquitecturas de deep learning:

1. **Red Neuronal Convolutiva de Grafos (GCN) + RNN/GRU/LSTM:** Esta arquitectura combina una GCN para modelar la red de transmisión eléctrica y capturar interacciones espaciales, con una capa recurrente (RNN o GRU) para modelar las dependencias temporales. Los nodos en la GCN representan plantas de energía o centros

de demanda, y las aristas representan las líneas de transmisión y sus restricciones de capacidad. Las capas recurrentes permitirán al modelo capturar las relaciones dinámicas en el tiempo, optimizando así la predicción del CMg.

2. **Transformer para Series Temporales:** Los Transformers se aplicarán a los datos de series temporales para capturar patrones de largo plazo y relaciones temporales en el CMg y la demanda energética. La atención temporal permitirá que el modelo identifique eventos críticos en la serie de precios y prediga tendencias a largo plazo.
3. **Transformers + CNN para Series Temporales:** Este enfoque combinará la capacidad de las CNNs para extraer patrones locales en series temporales (como estacionalidades intradía) con la capacidad de los Transformers para capturar relaciones temporales de largo alcance, permitiendo una representación robusta de los datos temporales y la variabilidad de los precios.

## 5. Aporte Científico Principal

El aporte científico de este proyecto se fundamenta en la *comparación y análisis de modelos avanzados de deep learning* para un problema de predicción en la industria energética, una aplicación donde tradicionalmente se han utilizado modelos estadísticos o de aprendizaje supervisado básico. El proyecto innovará en los siguientes aspectos:

- **Análisis Comparativo de Arquitecturas:** Pocos estudios comparan de forma directa arquitecturas de grafos (GCNs combinadas con RNN/GRU), Transformers, y modelos híbridos para la predicción de series temporales en sistemas de energía. Esta comparación proporcionará información valiosa sobre la efectividad de cada enfoque en un sistema con restricciones espaciales y temporales complejas.
- **Adaptación de GCN + RNN/GRU para Predicción de Precios Energéticos:** Aunque las GCNs son comunes en sistemas de recomendación o en análisis de redes, su aplicación en la predicción de precios en un sistema energético con restricciones de transmisión y dependencias temporales es novedosa. Este trabajo explorará cómo la estructura de la red y la evolución temporal afectan la predicción de precios y evaluará la capacidad de esta combinación para capturar interdependencias espaciotemporales.
- **Aplicación de Técnicas de Deep Learning para Modelar Variabilidad de CMg:** La inclusión de técnicas como Transformers y Transformers + CNN permite capturar patrones de precios de largo plazo y corto plazo en la demanda energética,

ampliando la aplicabilidad de estos modelos en contextos de alta variabilidad y volatilidad de precios.

## 6. Conclusión

Esta propuesta establece las bases para un estudio comparativo que no solo busca predecir el CMg de manera precisa, sino también determinar qué arquitecturas de deep learning son las más adecuadas en un sistema con interacciones espaciales y temporales complejas. A través de esta comparación, el proyecto espera proporcionar una guía sobre qué tipo de modelo es más adecuado para problemas similares en la industria energética, con aplicaciones en arbitraje, optimización de almacenamiento y gestión de transmisión.