

Optimización económica de arbitraje de BESS a través de pronóstico de costos de mercado spot de energía en el Sistema Eléctrico Nacional chileno

Gonzalo Iglesias, Nicolás Sotelo, Max Cruz
Pontificia Universidad Católica de Chile

1 de noviembre de 2024

Resumen

El precio de venta de la energía (Costo Marginal o CMg) en el mercado spot chileno se determina a través del el costo de la unidad más cara actualmente despachada en el sub-sistema respectivo. Para optimizar la rentabilidad de BESS que retiran e inyectan al sistema mediante el mercado spot es crucial tener una estimación de los costos en el corto plazo (24-48 horas). Dado que el CMg depende principalmente de la demanda del sistema, la disponibilidad de energía renovables no convencionales y la disponibilidad del parque convencional, sería posible realizar un pronóstico de ERNC utilizando técnicas de Machine Learning. En este trabajo se realiza un análisis de performance de diferentes arquitecturas de redes neuronales para el pronóstico, incluyendo el uso de una combinación de Red Neuronal Convolutiva de Grafos (GCN) y RNN/GRU/LSTM; un Transformer para series temporales; y un modelo híbrido Transformer + CNN para capturar patrones estacionales y relaciones de largo alcance. ...

eléctrico nacional (SEN) se vea afectado por congestiones de transmisión, las cuales no dan abasto para llevar toda la energía producida en la zona norte del país a las zonas centrales donde hay mayores consumos. Esta condición de exceso de oferta de energía en la zona norte conlleva el CMg de la zona afectada se desplome y que las centrales ERNC deban disminuir su producción de energía en un fenómeno conocido como *vertimiento* o *curtailment*.




Figura 1: Cambio en la Matriz de Generación del SEN

1. Introducción

Durante la última década, Chile ha experimentado un rápido crecimiento en la penetración de energías renovables no convencionales (ERNC), en particular en la zona norte, como se observa en la figura ?? , el cual no ha sido acompañado en la misma medida por un aumento en la capacidad de transmisión, cuyos proyectos tienen un tiempo de desarrollo significativamente mayor. Esto ha llevado a que el sistema

La disminución de la producción y la baja de los CMg afectan por partida doble la rentabilidad de las centrales ERNC, ya que no solo inyectan menos energía, sino que la que logran entregar al sistema se vende a costo muy bajo o 0. Este escenario ha generado otro boom en la industria, que busca aminorar estos efectos a través del desarrollo de proyectos de almacenamiento de energía (BESS) que les permitirá almacenar la energía generada en horas de exceso de

esta e inyectarla en horas donde hay mejores precios. Pero para rentabilizar estos proyectos es necesario maximizar el spread del CMg, es decir, comprar la energía en las horas de menor precio y luego venderla en las de mayor CMg. Para esto, trabajaremos con distintos modelos, de modo de identificar la arquitectura que mejor se adapte a la tarea del pronóstico de los costos.




Figura 2: Comparación perfil diario CMg promedio pre y post escenario de congestión en barra Crucero 220kV

2. Metodología

2.1. Datos

Para la el entrenamiento de los modelos, contamos con una serie de datos los cuales son considerados drivers claves del costo marginal, adicionales al CMg histórico el cual será nuestra variable objetivo.

- Demanda Nacional

Valores historicos de la demanda electrica nacional en MW desde el 2018 a la fecha y con resolución horaria.

- Disponibilida ERNC

Pronóstico histórico de la disponibilidad de ERNC en MW por central desde el 2018 a la fecha y con resolución horaria.

- Matriz de Generación

Potencia instalada por tecnología en MW a lo largo del tiempo desde 2018 hasta la fecha.

- Cotas de Embalse

Cotas de embalse de las principales centrales hidroeléctricas del sistema.

La combinación de estos datos, con distintas escalas de estacionalidad, nos entregarán unas condiciones de borde importantes para el pronóstico del CMg.

2.2. Modelos

Para abordar el problema, se compararan tres arquitecturas de deep learning, en las que se busca un enfoque novedoso para enfrentar este problema de series de tiempo:

1. Red Neuronal Convolutional de Grafos (GCN) + RNN/GRU/LSTM

Esta arquitectura combina una GCN para modelar la red de transmisión eléctrica y capturar interacciones espaciales, con una capa recurrente (RNN o GRU) para modelar las dependencias temporales. Los nodos en la GCN representan subestaciones, y las aristas representan las líneas de transmisión y sus restricciones de capacidad.

2. Transformer para Series Temporales

Transformers se aplicaran a los datos de series temporales para capturar patrones de largo plazo y relaciones temporales en el CMg y la demanda energética. La atención temporal permitira que el modelo identifique eventos críticos en la serie de precios y prediga tendencias a largo plazo.

3. Transformers + CNN para Series Temporales

Este enfoque combinara la capacidad de las CNNs para extraer patrones locales en series temporales (como estacionalidades intradía) con la capacidad de los Transformers para capturar relaciones temporales de largo alcance, permitiendo una representación robusta de los datos temporales y la variabilidad de los precios.