

Optimización del Arbitraje de BESS mediante el Pronóstico del Costo Marginal de Generación en el Sistema Eléctrico Nacional Chileno

Gonzalo Iglesias, Nicolás Sotelo, Maximiliano Cruz
Pontificia Universidad Católica de Chile

3 de noviembre de 2024

Resumen

El precio de venta de la energía (Costo Marginal o CMg) en el mercado spot chileno se determina por el costo de la unidad más cara despachada en el sub-sistema respectivo. Para optimizar la rentabilidad de BESS que retiran e inyectan al sistema mediante el mercado spot es crucial tener una estimación de los costos en el corto plazo (24-48 horas). Este trabajo realiza un análisis de rendimiento de tres arquitecturas avanzadas de deep learning para el pronóstico del CMg: una Red Neuronal Espacio-Temporal de Grafos (STGNN) combinada con GRU, un Transformer para series temporales (Informer) y un modelo híbrido Hybrid TFT-CNN para capturar patrones estacionales y relaciones de largo alcance. El proyecto busca identificar la arquitectura más precisa para apoyar la toma de decisiones en el almacenamiento energético, optimizando el arbitraje.

1 Introducción

Durante la última década, Chile ha experimentado un rápido crecimiento en la penetración de energías renovables no convencionales (ERNC) en la zona norte, lo que no ha sido acompañado por un aumento equivalente en la capacidad de transmisión. Esto ha causado congestiones en la transmisión, lo cual afecta el Costo Marginal de Generación (CMg) al generar precios bajos o nulos en las zonas con sobreoferta.

Este proyecto presenta una adaptación de arquitecturas avanzadas de deep learning al contexto del sistema eléctrico chileno, caracterizado por una alta penetración de ERNC y congestión en la transmisión, factores que impactan la variabilidad en el CMg. A diferencia de estudios previos, nuestra propuesta se enfoca en capturar tanto las relaciones espacio-temporales en las redes de transmisión como los patrones temporales de largo alcance, empleando un enfoque multimodal.

Para maximizar la rentabilidad de BESS, es crucial identificar patrones en la variabilidad del CMg en el corto plazo (24-48 horas). En este proyecto se evaluarán tres arquitecturas de deep learning con el objetivo de comparar su efectividad en la predicción de CMg y contribuir al conocimiento científico mediante el análisis de su capacidad para capturar patrones de largo y corto alcance en series temporales energéticas.




Figura 1: Cambio en la Matriz de Generación del SEN




Figura 2: Comparación perfil diario CMg promedio pre y post escenario de congestión en barra Crucero 220kV

2 Metodología

2.1 Datos

Para el entrenamiento de los modelos, contamos con una serie de datos que son considerados drivers claves del costo marginal, adicionales al CMg histórico, el cual será nuestra variable objetivo. Los datos incluyen:

- **Demanda Nacional:** demanda eléctrica en MW, desde 2018 con resolución horaria.
- **Disponibilidad de ERNC:** pronóstico de ERNC en MW por central, por hora.
- **Matriz de Generación:** potencia instalada por tecnología en MW desde 2018.
- **Cotas de Embalse:** niveles de embalse de las principales centrales hidroeléctricas.

Estos datos forman una serie temporal extensa con variaciones estacionales y eventos de congestión, lo cual presenta un desafío en el modelado debido a la alta dimensionalidad y variabilidad intrínseca.

2.2 Modelos

Para abordar el problema, evaluamos tres arquitecturas de deep learning:

1. **STGNN + GRU:** Una Red Neuronal Espacio-Temporal de Grafos (STGNN) con una capa GRU permite capturar tanto las dependencias espaciales entre diferentes zonas de transmisión como las relaciones temporales en la variación del CMg. La STGNN modela la topología de la red eléctrica para entender las interacciones entre nodos en el espacio y cómo evolucionan en el tiempo.
2. **Informer:** Un Transformer optimizado para series largas, ideal para detectar patrones de largo alcance en la demanda y disponibilidad energética, aprovechando su arquitectura para el procesamiento eficiente de secuencias.
3. **Hybrid TFT-CNN:** Utiliza CNN para captar estacionalidades de corto plazo y mecanismos de atención para identificar relaciones de largo plazo, lo que resulta útil en contextos de variabilidad del CMg.

La elección de estos modelos responde a su capacidad para capturar tanto relaciones espaciales y temporales a través de la STGNN, como dependencias de largo alcance mediante el Transformer, lo que permite adaptar las predicciones de CMg al contexto único del sistema energético chileno.

3 Conclusión

Este proyecto proporciona un enfoque comparativo para la predicción del CMg en el sistema energético chileno, utilizando arquitecturas avanzadas de deep learning. A través del análisis del rendimiento de STGNN + GRU, Informer y Hybrid TFT-CNN, esperamos identificar la arquitectura que mejor capte la complejidad espaciotemporal del CMg, optimizando el arbitraje en BESS y aportando un nuevo enfoque para el manejo de la volatilidad en sistemas energéticos.